



Universidade Federal do ABC
Centro de Matemática, Computação e Cognição
Projeto de Graduação em Computação

Análise do desenvolvimento de uma inteligência artificial condutora de um veículo

Vítor Guilherme Antunes

Santo André - SP, Dezembro de 2023

Vítor Guilherme Antunes

Análise do desenvolvimento de uma inteligência artificial condutora de um veículo

Projeto de Graduação apresentada ao Centro de Matemática, Computação e Cognição, como parte dos requisitos necessários para a obtenção do Título de Bacharel em Ciência da Computação.

Universidade Federal do ABC – UFABC
Centro de Matemática, Computação e Cognição
Projeto de Graduação em Computação

Orientador: Fernando Teubl Ferreira

Santo André - SP
Dezembro de 2023

Vítor Guilherme Antunes

Análise do desenvolvimento de uma inteligência artificial condutora de um
veículo/ Vítor Guilherme Antunes. – Santo André - SP, Dezembro de 2023-
45 p. : il. (algumas color.) ; 30 cm.

Orientador: Fernando Teubl Ferreira

Dissertação (Mestrado) – Universidade Federal do ABC – UFABC

Centro de Matemática, Computação e Cognição

Projeto de Graduação em Computação, Dezembro de 2023.

1. Palavra-chave1. 2. Palavra-chave2. I. Orientador. II. Universidade xxx. III.
Faculdade de xxx. IV. Título

CDU 02:141:005.7

Agradecimentos

Agradeço a Xuxa, meus pais, cachorro, gato e papagaio, por ...

Agradeço ao meu orientador, XXXXXXXXX, por todos os conselhos, pela paciência e ajuda nesse período.

Aos meus amigos ...

Aos professores ...

À XXXXXX pelo apoio financeiro para realização deste trabalho de pesquisa.

*“Não sei o que,
não sei o que,
não sei o que lá.”
(Autor Desconhecido)*

Resumo

Segundo a ABNT, o resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. Umas 10 linhas (...) As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto.

Palavras-chaves: latex. abntex. editoração de texto.

Abstract

This is the english abstract.

Keywords: latex. abntex. text editoration.

Lista de ilustrações

Figura 1 – Interface da Unity3D. A janela 1 é a hierarquia, 2 é a janela de projeto, 3 é visualização da cena e 4 é o inspetor	10
Figura 2 – diagrama da interação do agente com o ambiente. Adaptado de Sutton e Barto (2018)	12
Figura 3 – Diagrama das funções valores. Ao estado s é atribuído o valor $v_\pi(s)$, a cada uma das ações é atribuído o valor $q_\pi(a_n s)$ e tem probabilidade $\pi(a_n s)$ de ser selecionada. Adaptado de Sutton e Barto (2018)	14
Figura 4 – Visão superior o cenário urbano criado para o treinamento do veículo .	23
Figura 5 – Rota vista de perspectiva isométrica, o agente posicionado a origem ao canto esquerdo, com os <i>checkpoints</i> ao longo do percurso até o destino no canto direito.	24
Figura 6 – Exemplo do agente e seus raios perceptores, é possível ver 6 raios laterais se chocando com as calçadas ao lado, o raio frontal se chocando com o <i>checkpoint</i>	25

Lista de tabelas

Lista de abreviaturas e siglas

IA	Inteligência Artificial
AS	Aprendizado Supervisionado
MDP	Processo de Decisão de Markov
PGM	Policy Gradient Method (Método de política gradiente)
PPO	Proximal Policy Optimization (Algoritmo de)
SAC	Soft Actor Critic

Lista de símbolos

\in	Pertence
\doteq	Se define por
S	Conjunto de estados
S^+	Conjunto de estados onde há estado terminal
A	Conjunto de ações
$A(s)$	Conjunto de ações válidas no estado s
π	Política
π_*	Política ótima
$v(s)$	função valor do estado s
$v_\pi(s)$	função valor do estado s sob política π
$q(s, a)$	função valor do ação-estado
$q_\pi(s, a)$	função valor do ação-estado sob política π
γ	Constante de desconto

Sumário

	Introdução	1
	Justificativa	2
	Objetivos	2
	Etapas do estudo	2
I	PREPARAÇÃO DA PESQUISA	5
1	FUNDAMENTAÇÃO TEÓRICA	7
1.1	Veículos autônomos	7
1.2	Motores de jogos	8
1.2.1	Editor da Unity3D	9
1.3	Inteligência Artificial	10
1.3.1	Aprendizado de máquina	11
1.4	Aprendizado por reforço	11
1.4.1	Processo de tomada de decisão	12
1.4.2	Algoritmos de otimização de política e conceito de aproximação	15
1.4.3	Métodos de gradiente de política e de ator-crítico	16
2	ESTADO DA ARTE	17
3	MATERIAIS E MÉTODOS	19
II	PROPOSTA	21
4	MODELO PROPOSTO	23
4.1	Ambiente	23
4.2	Agente	24
4.3	Roteiro de treino	25
III	PARTE FINAL	27
5	RESULTADOS E DISCUSSÃO	29
5.1	Base de Dados	29
5.2	Considerações Finais	29
	Conclusão e Trabalhos Futuros	31

REFERÊNCIAS	33
 APÊNDICES	 35
APÊNDICE A – PRIMEIRO APÊNDICE	37
APÊNDICE B – SEGUNDO APÊNDICE COM TÍTULO TÃO GRANDE QUANTO SE QUEIRA PORQUE ELE JÁ FAZ A QUEBRA DE LINHA DA COISA TODA	39
 ANEXOS	 41
ANEXO A – NOME DO PRIMEIRO ANEXO	43
ANEXO B – NOME DE OUTRO ANEXO	45

Introdução

No passado eram veículos eram, em grande parte, máquinas mecânicas, com poucos recursos eletrônicos. Hoje em dia, diversos avanços foram feitos nos carros modernos, e estes já estão equipados com variadas tecnologias assistentes como controle de tração, freios ABS e de emergência, piloto automático, entre outros recursos que dependem de sensores e que tomam decisões que controlam parcialmente o veículo, visando segurança e conforto ao condutor.

Veículos que possuem as assistências mencionadas acima comumente são chamados de "autônomos", porém neste artigo trataremos por "carro autônomo" um veículo que seja capaz de conduzir-se sem depender de um humano. De acordo com o padrão SAE J3016 a autonomia de veicular é dividida em níveis que vão do zero ao cinco, os recursos citados são no máximo nível 2, um veículo para ser "autônomo" seria de nível 3 ou maior ([SAE \(2014\)](#)), porém para atingir este grau de autonomia é necessário mais do que sensores e controladores que dão instruções diretas ao carro.

Nas duas últimas décadas houve um aumento na presença de tecnologias como Inteligência Artificial e **Aprendizado de Máquina** no cotidiano das pessoas. Corretores ortográficos, reconhecimento facial, algoritmos de recomendação de leitura, música ou compra são alguns exemplos de diversos outros que até então estavam apenas disponíveis em lugares específicos com laboratórios de pesquisa, mas agora já são amplamente aplicadas.

Existem três paradigmas de aprendizado de máquina: **aprendizado supervisionado**, **não supervisionado** e **aprendizado por reforço**. Este último aborda aprendizado que envolvam exercer uma atividade, nele, o **agente** durante seu treino, aprimora uma tarefa após várias tentativas e erro onde é premiado quando age corretamente e penalizado caso contrário. Este artigo introduzirá os dois primeiros paradigmas e discorrerá mais detalhadamente sobre o **AR**. Embora o **AS** também é necessário para a tarefa, ele é mais usado em reconhecimento de elementos no ambiente, algo que está fora do escopo deste projeto.

Quando tenta-se criar uma automato que exerça uma atividade complexa como condução de um veículo, a abordagem clássica que usa algoritmos com condicionais e instruções direta é insuficiente para tal, isto deve-se ao fato de que é inviável criar manualmente uma tabela de comandos dado certas condições, a lista tenderia ao infinito. Utilizando de um paradigma de AM como **aprendizado por reforço** se faz necessário pois o automato irá, após sucessivas tentativas, dominar a técnica de conduzir um veículo.

Este artigo propõe-se a apresentar um estudo do que é necessário para criar um agente condutor de um veículo dentro de um simulador que saiba percorrer um dado

trajeto em um ambiente urbano. Será analisado como modelar um simulador, como quais sensores o veículo deve possuir, quais observações deve fazer do ambiente para evitar colisões, entre outros.

Justificativa

Uma das maiores causas de morte no Brasil é por conta de acidentes de trânsito, chegando a um total de 43 mil óbitos em um único ano (CARVALHO, 2016), é sabido também que grande causa dessas mortes é por falha humana por parte do condutor. Tendo em vista o avanço tecnológico na área de Inteligência Artificial vemos que vem se tornando viável o desenvolvimento de um modelo que seja capaz de conduzir um veículo automotivo em ambientes urbanos, dessa forma poderíamos ter em vias públicas condutores que não se distraiam e não cometam infrações de trânsitos.

Objetivos

O objetivo deste projeto é criar uma simulação que se aproxime o máximo possível a um cenário real e com isso analisar todos os elementos que são necessários para que o agente aprende a exercer sua tarefa mais central: conduzir o veículo de sua origem até seu destino.

- Analisar quantos sensores o veículo deve possuir, como devem ser posicionados.
- Como a adição gradual de cada elemento de trânsito afeta o agente (elementos como outros veículos, semáforos e pedestres)
- Diferença entre os algoritmos de otimização de política **SAC** e **PPO** afetam a convergência do treino e o resultado final

Etapas do estudo

Podemos abstrair o treino em três segmentos: **ambiente**, **agente** e **algoritmo**. Ambiente engloba qualquer coisa que o agente interage, por exemplo, o cenário urbano como as ruas e calçadas, e uma inclusão de elementos de trânsito como outros veículos, semáforos ou pedestres seriam alterações no ambiente. O segundo segmento se refere ao aprendizado, alterações feitas nas informações recebidas pelo agente como distância dos obstáculos mais próximos, velocidade do veículo, distância e localização do destino, etc, mudanças feitas nestas propriedades ou em semelhantes são alterações no agente. Finalmente, algoritmo se refere ao esquema dos algoritmos usados (PPO ou SAC) e seus hiper-parâmetros.

A primeira etapa deste estudo o agente terá de aprender a conduzir como se estivesse sozinho, isso permitirá entender melhor o que é necessário para fazer com que o aprendiz precisa para percorrer qualquer trajeto dado como objetivo. Isto é o ambiente inicialmente será apenas uma cidade vazia e a cada etapa deve-se aumentar a complexidade dele visando se aproximar da realidade. Em cada etapa as mudanças devem seguir a ordem dos segmentos, com uma certa flexibilidade, ou seja, um aumento de realismo no ambiente deve levar a alterações sensoriais no agente para se adaptar ao novo cenário e calibrar os hiper-parâmetros dos algoritmos usados.

Em cada etapa então deve-se:

- Analisar quantos e como serão dispostos os sensores o veículo deve possuir;
- Como é o desempenho usando cada algoritmo (PPO ou SAC), como as alterações dos hiper-parâmetros afetam o treino e a convergência/otimização do comportamento;

Parte I

Preparação da pesquisa

1 Fundamentação teórica

Neste capítulo será introduzido os conceitos e fundamentos das teorias e tecnologias utilizadas neste projeto. Será abordado sobre autonomia de veículos como o que define um carro autônomo e os diferentes níveis de autonomia. Também abordará o que é um motor de jogo e a principal ferramenta que usaremos para desenvolver um ambiente simulado, a Unity 3D. Por fim, definição de IA, os paradigmas de aprendizado de máquina com um aprofundamento em aprendizado por reforço.

1.1 Veículos autônomos

A SAE (Society of Automotive Engineers) define 6 níveis de autonomia para veículos, do zero ao cinco ([SAE \(2014\)](#)). O primeiro, nível zero, não possui automação de direção alguma, é limitado a apenas a tecnologias de assistência como freios ABS ou freio automático emergencial. Um veículo com automação de nível um já passa a possuir alguns recursos que ajudam na direção, como controle para manter o carro na via, controle de velocidade a fim de manter distância de outro veículo a frente. Os níveis dois e três são definidos por, respectivamente, "direção parcialmente automática" e "direção automática condicional", a diferença de ambos pode ser bem sutil, pois em ambos os casos a automação teria o controle do volante, acelerador e freio, no primeiro seria apenas para atividades mais simples, como dirigir na estrada mantendo a velocidade e distâncias, enquanto no nível três o veículo assumiria o controle por um período, podendo até fazer manobras mais avançadas, como ultrapassar um automóvel mais lento a frente. Em ambos os níveis ainda é necessário a atenção máxima do condutor para assumir o controle quando for necessário.

Nos últimos dois níveis de autonomia, temos um veículo que seria capaz de exercer qualquer atividade sem intervenção humana, no nível 4 não seria necessário que o motorista estivesse a condução, só assumiria o controle quando necessário, nesses níveis é capaz inclusive que o automóvel assuma o controle quando necessário, e o mesmo poderia ainda nem possuir volante ou pedais.

Atualmente veículos com autonomia de nível zero a dois, já estão presentes no mercado, nesse artigo estamos interessados em discutir sobre os carros autônomos de nível 3 ou mais, isto é, automóveis que possuam um alto nível de autonomia, o sistema deles podem ser divididos em quatro componentes, cada um deles usam aprendizado de máquina de formas diferentes, são eles: planejamento de rota, decisões comportamentais, controle de moção e controle veicular ([Paden et al. \(2016\)](#)).

O planejamento de rota se trata de definir o trajeto a ser percorrido pelo veículo,

isto é, o cálculo do percurso da origem ao destino, imaginar uma cidade com suas ruas, intersecções e pontos de destino como se fosse um grafo ponderado com arestas e vértices e aplicar um algoritmo de busca como Dijkstra não é o suficiente para gerar uma solução eficiente, então para isso requer algo que se utilize de outros dados como informação histórica e em tempo real para achar o melhor caminho a ser percorrido em um dado dia da semana, em um dado horário e clima.

Definida a rota, o veículo deve ser capaz de percorrer a mesma tendo em consideração todos os participantes do tráfego e as regras de trânsito, isso envolve uma complexidade de comportamento que vai além de apenas saber conduzir o veículo, então o componente de decisões comportamentais deve saber selecionar ações apropriadas para cada situação. A condução do automóvel em uma rodovia é diferente da condução em um cruzamento em uma rua urbana, onde ele deve parar o veículo e cruzar quando não há nenhum outro veículo ou pedestre no caminho.

A partir do momento que o comportamento foi selecionado, o controle de moção do automóvel autônomo que decide como este vai se locomover, mudança de faixa, conversão a direita, parar o veículo, avançar ao sinal verde, etc, todos essas ações devem ser realizadas de modo que não cause colisões, evitando obstáculos, e devem de ser realizada de forma que não cause desconforto aos passageiros.

O controle do veículo se define pelo controle dos atuadores mecânicos do automóvel para que tenha uma resposta em retorno, essa constante troca de informação é necessária para o controle de moção do veículo atue apropriadamente.

1.2 Motores de jogos

Um motor de jogo (do inglês *game engine*) é um *software* com o objetivo primário de se criar jogos eletrônicos. Estes programas inclui diversas ferramentas que auxiliam o desenvolvedor de jogos a criar seu produto, não existe uma definição sobre quais destas um software deve possuir para ser considerado um motor de jogo, mas frequentemente possuem módulos que lidam com *input* de usuário, renderização de gráficos 2D e 3D, som, motor de física (onde se lida com gravidade e colisão), animação, gerenciamento de memória entre outros ([Andrade \(2015\)](#)).

Como o objetivo é focado no desenvolvimento de uma inteligência artificial para um simulador de carro autônomo, um motor de jogo possui meios que facilitariam o trabalho, não seria necessário desenvolver do zero a renderização dos modelos dos ambientes como veículos, ruas, calçadas, prédios, etc, também não seria necessário desenvolver todo o complexo cálculo de física como força, gravidade, colisão de objetos, peso do veículo, entre outros. Com isso permite que o foco do trabalho a ser feito se limite o máximo possível à análise da IA.

Inicialmente foi considerado o uso de outros motores de jogo, como a Unreal Engine 4 (software da Epic Games, Inc.) e a Godot Engine (Open Source sob licença MIT), embora haja uma preferência natural por uma ferramenta open source do que um software proprietário para realizar esta tarefa, a Unity 3D possui uma comunidade muito maior que o Godot Engine de acordo com ([ITCH.IO \(2023\)](#)) e ([SteamDB \(2023\)](#)), ambas as fontes são portais que servem para divulgação e venda de jogos publicados por desenvolvedores individuais ou empresas, a Unity 3D é mais utilizada em ambas as plataformas. A Unity 3D possui também seu acervo de recursos criados pela comunidade conhecido como Unity Asset Store onde é possível obter modelos 3D, efeitos sonoros e até modelos genéricos de jogos para se construir algo em cima disso.

A Unity 3D também possui uma biblioteca de ferramentas própria para criação de agentes inteligentes chamada de **Unity ML Agent Toolkit**, que foi escrita usando **Pytorch**, uma biblioteca **Python** para criação de redes neurais. A Unity ML Agent toolkit oferece um aparato para se criar um agente inteligente, onde é configurado sensores e ações (o que seria a primeira e última camada de uma rede neural) podendo ser treinado usando aprendizado por reforço, por imitação, neuroevolução, entre outros.

1.2.1 Editor da Unity3D

Dentre as principais janelas da interface da Unity3D, temos: hierarquia, projeto, visualização da cena e inspetor. A primeira se trata dos elementos que há dentro da cena (pode-se entender como sendo um trecho do jogo, como este projeto contém apenas uma única cena não é necessário que o leitor entenda tudo que uma cena pode ser), estes elementos são chamados de *GameObjects*, eles são uma abstração de qualquer item dentro do jogo, incluindo o personagem que o jogador controla, o cenário com o qual interage, a "câmera" com o qual o jogo é visto também é um *GameObject*. A primeira janela é chamada de hierarquia porque o conjunto destes objetos podem formar uma estrutura em árvore, por exemplo, podemos criar um objeto "árvore" que conteria os objetos "raiz", "tronco" e "folhas" como seus objetos aninhados. Na seção da proposta é explicado a estrutura deste projeto com mais detalhes.

A janela de projeto estão os arquivos do projeto, é um diretório do projeto criado pela Unity3D onde deve conter arquivos de efeitos sonoros, códigos-fonte do desenvolvedor, fontes, modelos 2D e 3D, texturas, etc. A visualização da cena é uma janela que permite o desenvolvedor ter uma noção visual da disposição dos *GameObjects*, desta forma ele consegue posicioná-los mais apropriadamente, também consegue ver se a dimensão e escala deles estão coerentes.

A última janela é o inspetor, nela é exibido os detalhes dos *GameObjects*, isto é, os *components* destes. Como foi explicado anteriormente, os *GameObjects* podem assumir diversas funcionalidades, e são os componentes que permitem isso, por exemplo,




Figura 1 – Interface da Unity3D. A janela 1 é a hierarquia, 2 é a janela de projeto, 3 é visualização da cena e 4 é o inspetor

o componente *Transform*, comum a todos os objetos da cena define as coordenadas (ou posição) que o objeto se encontrará na cena, sua rotação e escala, já os *components Mesh Filter* e *Mesh Renderer* são responsáveis pela renderização 3D de um objeto, isto é, sua forma e aparência.

Os conceitos de como funciona um desenvolvimento de jogo dentro do editor da Unity3D podem não ter ficado claro ao leitor, porém na parte sobre o sistema proposto deste artigo é explicado em mais detalhes a estrutura do projeto.

1.3 Inteligência Artificial

Não existe uma definição única sobre o que é Inteligência Artificial (IA), o mesmo pode ser dito quanto ao seu objetivo. Porém, para compreender melhor o seu escopo, pode-se dizer que está interessada em criar um programa de computador que faça uma ou mais dos seguintes tópicos: pensar humanamente, agir humanamente, pensar racionalmente e agir racionalmente. Pensar pode ser entendido como o processo de pensamento, de compreender e argumentar enquanto agir pode ser entendido como tomar ações e possuir um certo comportamento. Humanamente mediria o quanto a Inteligência Artificial consegue se aproximar de um desempenho humano (agindo ou pensando), e racionalmente é quando há o interesse em pensar ou agir de forma ideal, isto é, que faça "a coisa certa" (Russell e Norvig (2009)).

Uma IA que age racionalmente, pode ser entendido como um programa de computador que toma decisões autonomamente. De fato, qualquer algoritmo pode ser criado para tomar decisões de acordo com uma série de condições, mas é esperado mais de um **agente racional**, ele é criado para observar o ambiente em que está inserido e tomar

decisões por um período prolongado, adaptando-se a qualquer mudança e procurando cumprir seu **objetivo** fazendo isso de forma ideal, não cometendo erros, e quando estes forem inevitáveis, deverá agir de forma a minimizar o dano causado (Russell e Norvig (2009)).

Para desenvolvimento de um veículo autônomo que este artigo se propõe a estudar, não basta um algoritmo definindo condições e instruções, isto seria uma abordagem insuficiente tanto em eficiência quanto em praticidade em seu desenvolvimento. Seria então necessário uma agente racional, que possua as características descritas no parágrafo anterior, que saiba observar o ambiente em sua volta e **aprenda** a agir de acordo. A seção abaixo elabora mais sobre esta área específica da Inteligência Artificial.

1.3.1 Aprendizado de máquina

Aprendizado de máquina é qualquer processo automatizado que tem como objetivo reconhecer um padrão dentro de um conjunto de dados (Kelleher, Namee e D'Arcy (2015)), em aprendizado de máquina o projetista cria um agente-aprendiz, fornece os dados e define um objetivo a fim de fazer seu agente melhorar seu desempenho na tarefa após sucessivas iterações observando os dados o tomando decisões.

Há dois paradigmas em AM que valem a pena ser mencionados brevemente antes de irmos ao que será utilizado no projeto, são eles: Aprendizado supervisionado, não-supervisionado. O primeiro lida mais com problemas de classificação, ao agente é fornecido dados rotulados, e ao analisá-los, se o treino foi efetivo, o agente seria capaz de atribuir um rótulo a um novo registro com uma alta acurácia. O Aprendizado não-supervisionado envolve dados sem rótulos, o objetivo do agente é encontrar uma estrutura oculta que conecte os dados, este processo é chamado de clusterização. Embora possa haver espaço para estes paradigmas no campo de autonomia veicular, eles não estão no escopo deste projeto.

1.4 Aprendizado por reforço

No aprendizado por reforço o objetivo é sempre fazer com que o agente aprenda a executar uma tarefa, se trata de ensiná-lo a como fazer. O agente está inserido em um ambiente e a ele é dado um objetivo, com isso ele deve aprender a tomar as decisões corretas nas situações apropriadas visando seu propósito. O aprendiz não é instruído sobre quais ações tomar em dadas circunstâncias, ao invés disso o agente aprenderá a tomar as decisões com base na orientação do treinamento, que envolve em premiá-lo quando agir idealmente ou penalizá-lo caso contrário. Esse parecer que o agente recebe é um valor numérico a ser maximizado por ele, e o dever do projetista é programar os critérios que decidem não somente o que é recompensador ou penalizador, mas o quanto é.

A seguir será formalizado como esse processo ocorre, toda esta seção é baseada em Sutton e Barto (2018), exceto quando abordarmos sobre os algoritmos de otimização de política. É importante esclarecer aqui que a formalização a seguir se trata de tipos de problemas mais simples do que iremos lidar neste projeto, porém essa introdução é necessária para compreender os conceitos mais avançados serão vistos posteriormente.

1.4.1 Processo de tomada de decisão

Neste paradigma, o *agente* toma uma decisão A_t que afeta o *ambiente* o qual está inserido, que retorna a ele um estado S_{t+1} e uma recompensa R_{t+1} . O conjunto S representa todos os estados possíveis do ambiente, cada estado s representa toda a observação que o agente tem do sistema.




Figura 2 – diagrama da interação do agente com o ambiente. Adaptado de Sutton e Barto (2018)

Usando o jogo da velha de exemplo, o conjunto S representaria todas as configurações possíveis do tabuleiro, um estado $S_t \in S$ seria uma configuração específica, sendo que S_0 poderia representar o tabuleiro vazio antes de qualquer jogada. Uma ação $a \in A$ seria uma jogada e por fim $t \in \{0, 1, 2, 3, \dots, T\}$ as etapas do jogo até a etapa final T .

Essa sequência de estados, ações e recompensas é chamada de *trajetória* e pode ser escrita da seguinte forma:

$$S_0, A_0, R_1, S_1, A_1, R_2, S_2, A_2, \dots, R_n, S_n \quad (1.1)$$

Esse sistema é conhecido como **Processo de Decisão de Markov** (MDP, do inglês Markov Decision Process), é uma formalização de problemas que possuem um número *finito* de estados, ações e recompensas, podendo ser **estocástico**, isto é, não é possível antecipar com exatidão qual será S_{t+1} dado S_t e A_t e de **tempo discreto**. Dito isso, temos a seguinte distribuição de probabilidade p de um estado s' ocorrer após o agente tomar a decisão a no estado s :

$$p(s', r|s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\} \quad (1.2)$$

E por ser uma distribuição de probabilidades, temos:

$$\sum_{s' \in S} \sum_{r \in R} p(s', r|s, a) = 1, \text{ para todo } s \in S, a \in A(s) \quad (1.3)$$

Sendo $A(s)$ é o conjunto de todas as ações que podem ser tomadas no estado s .

Em um MDP, a probabilidade de cada valor de S_t e R_t depende *apenas* de S_{t-1} e A_{t-1} e de nenhum outro estado anterior a este. Então um estado S_t contém toda a informação de interações passadas entre o agente e o ambiente, essa característica do estado é chamada de **propriedade de Markov**.

O comportamento do agente é moldado pelas recompensas que recebe a cada ação que toma, este sinal de recompensa é o que indica se o agente está executando a tarefa apropriadamente ou não. Diferente dos estados S e ações A , que podem assumir qualquer forma, o conjunto R é um conjunto de números reais: $r \in R \subset \mathbb{R}$. A fórmula que deve ser maximizada é chamada de **retorno esperado**, é denotado por G_t :

$$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \dots + R_T, \quad (1.4)$$

onde T é a última etapa que ocorre quando se atinge um **estado terminal**. Nem todas as tarefas possuem um estado terminal, mas as que têm são chamadas de **tarefas episódicas**. Usando o exemplo do jogo da velha, podemos entender que cada estado que define um vencedor ou define um empate onde nenhuma jogada mais pode ser feita, seja um estado terminal. Em contraste, se uma tarefa não possui fim, é chamada de **tarefa contínua**. Como tarefas contínuas teriam $T = \infty$ logo $G_t = \infty$ e se torna impossível calcular por um computador. Então para isso é aplicado um desconto γ na equação onde $0 \leq \gamma \leq 1$:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (1.5)$$

A **constante de desconto** γ representa o valor de recompensas futuras, caso $\gamma = 0$ o agente apenas se preocuparia em maximizar R_t independente dos valores de recompensas futuras. Quando se aplica um γ se aproxima de 1, mais se valoriza estados futuros e aumenta as chances de o agente tomar uma ação que tenha uma recompensa imediata menor mas maiores recompensas futuras.

Com isso chegamos a uma das partes centrais do RL, que é **funções valores**. Uma função valor é o que determina o quão importante é para o agente estar naquele estado,

isto é, seu valor que é determinado pelo retorno esperado de recompensas futuras daquele estado. Para poder calcular isso é preciso saber como o agente opera, logo, é preciso saber sua **política**.

A **política** (representada por π) é o mapeamento do estado para a ação a ser tomada, formalmente, $\pi(a|s)$ é a probabilidade de se tomar a ação a no estado s . Aprendizado por reforço é, basicamente, aprimorar a política do agente e a mesma tende a mudar de uma trajetória para outra (caso episódico) ou até mesmo dentro de uma trajetória.

A definição de uma função v valor do estado s sob uma política π é:

$$v_\pi(s) \doteq \mathbb{E}_\pi[G_t | S_t = s] \quad (1.6)$$

Da mesma forma, pode-se estimar o valor de uma ação, para isso há a **função valor da ação** $q_\pi(s, a)$, definida da seguinte forma:

$$q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t | S_t = s, A_t = a] \quad (1.7)$$

As funções valores v_π e q_π podem ser estimadas através de experiência. Pode-se começar com uma política que basicamente atribui a mesma probabilidade para qualquer ação em qualquer estado, conforme as recompensas vão sendo aplicadas o valor esperado do estado e da ação serão atualizados.




Figura 3 – Diagrama das funções valores. Ao estado s é atribuído o valor $v_\pi(s)$, a cada uma das ações é atribuído o valor $q_\pi(a_n|s)$ e tem probabilidade $\pi(a_n|s)$ de ser selecionada. Adaptado de [Sutton e Barto \(2018\)](#)

Sabemos que G_t é uma função recursiva de modo que $G_t \doteq R_{t+1} + \gamma G_{t+1}$. Com isso é fácil perceber que o mesmo se aplica para as funções valores, para qualquer política π em qualquer estado s , temos a seguinte função valor recursiva:

$$\begin{aligned}
v_\pi(s) &\doteq \mathbb{E}_\pi[G_t | S_t = s] \\
&= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} | S_t = s] \\
&= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) [r + \gamma \mathbb{E}[G_{t+1} | S_{t+1} = s']] \\
&= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_\pi(s')], \text{ para todo } s \in S
\end{aligned} \tag{1.8}$$

Resolver uma tarefa por aprendizado por reforço é, grosseiramente, encontrar uma política que retorne uma grande quantidade de recompensa no longo prazo. Uma política π é dita melhor que outra π' se e somente se $v_\pi(s) \geq v_{\pi'}(s)$, para todo $s \in S$. Em um MDP finito, é garantido que haja pelo menos uma **política ótima**, isto é, uma que seja melhor que qualquer outra para todos os estados, esta política é geralmente representada por π_* , neste caso ela deve utilizar uma *função valor do estado* também ótima:

$$v_*(s) \doteq \max_{\pi} v_\pi(s), \text{ para todo } s \in S \tag{1.9}$$

similarmente, para acharmos a *função valor da ação* ótima:

$$q_*(s, a) \doteq \max_{\pi} q_\pi(s, a), \text{ para todo } s \in S \text{ e } a \in A(s) \tag{1.10}$$

1.4.2 Algoritmos de otimização de política e conceito de aproximação

Nesta seção será abordado mais sobre os diferentes tipos de algoritmos de otimização de política, principalmente o PPO, SAC que estão disponíveis no ML-Agents da Unity 3D.

Existem muitas formas de se chegar aos valores das funções (1.9) e (1.10) e na política ótima, dentre elas pode-se citar programação dinâmica usando a equação (1.8) que é uma **equação de Bellman**, onde usa-se iteração para avaliar os estados e depois otimizar a política, e com a política otimizada reavalia os estados para então otimizar a política novamente, e assim por diante até que os valores dos estados convirjam para seus "valores verdadeiros".

Outro método seria **Monte Carlo**, que não assume total conhecimento do ambiente (condição necessária para otimizar com programação dinâmica) e utiliza-se de experiência prévia. Por fim temos **Q-learning** que combina um pouco dos dois. Apesar destes métodos terem suas aplicações, não discorreremos aqui sobre eles, pois, como foi explicado anteriormente, a tarefa que o agente condutor executará não é um MDP finito.

A condução de um veículo autônomo não possui um número finito de estados, pelo contrário, se considerarmos o uso de visão computacional com processamento de imagem a quantidade de estados possíveis se torna virtualmente infinito. Os problemas que um MDP finito resolve são **tabulares**, isto é, podem ser dispostos em uma tabela, onde se guardaria a relação com ações válidas, seus valores, etc. Além disso, um estado não irá

possuir a **propriedade Markov**, isto é, não possui informação passadas da interação agente-ambiente.

Para isso há os **métodos de aproximação**, onde a quantidade de estados possíveis é tão grande que podemos assumir que o agente nunca passará pelo mesmo estado novamente. Portanto, uma abordagem em que alterar um valor $v(s)$ não altera o valor de outro estado semelhante $v(s')$ não parece útil, ao invés disso precisamos assumir que a valorização de um estado implique na valorização de outro. Além disso, temos o fato de que é inviável calcular $v_*(s)$ para todo $s \in S$, então agora será explorado os métodos de **aproximação**, que se baseia em utilizar uma função valor do tipo $\hat{v}(s, \mathbf{w}) \approx v_*(s)$ e $\mathbf{w} \in \mathbb{R}^d$. Dessa forma \hat{v} pode ser tanto uma função linear com \mathbf{w} sendo um vetor dos coeficientes quanto uma rede neural com \mathbf{w} sendo os pesos das conexões.

1.4.3 Métodos de gradiente de política e de ator-crítico

Métodos de gradiente de política são uma abordagem diferente das já mencionadas acima, no caso a atualização da política não depende das funções valores das ações, em vez disso temos $\pi(a|s, \theta) = \Pr\{A_t = a|S_t = s, \theta_t = \theta\}$ para a probabilidade de ação a ser selecionada no tempo t dado que o ambiente se encontra no estado s com parâmetros $\theta \in \mathbb{R}^{d'}$. Agora o interesse é atualizar θ a fim de aprimorar a política da seguinte forma:

$$\theta_{t+1} = \theta + \alpha \widehat{\nabla J(\theta_t)}, \quad (1.11)$$

onde α é o tamanho do salto do gradiente e $\widehat{\nabla J(\theta_t)} \in \mathbb{R}^d$ é uma estimativa estocástica cuja expectativa se aproxima do gradiente da medida de desempenho em relação ao seu argumento θ_t . Qualquer método que obedeça a regra acima é um **método de gradiente de política** (PGM, do inglês Policy Gradient Method) podendo ou não utilizar de aproximação de função valor do estado $\hat{v}(s)$ descrito acima, caso utilize será considerado um **método de ator-crítico** (actor-critic method).

Como foi mencionado na introdução, o pacote ML-Agents possui dois algoritmos de aprendizado por reforço: o **PPO** e o **SAC**. O primeiro é a sigla para **Proximal Policy Optimization** e é um PGM que tem o diferencial de que ele alterna entre extrair dados da política e executar uma otimização em lotes dos dados extraídos, além de aproveitar de se aproveitar de TRPO (Trust Regional Policy Optimization) mas sem ser tão complicado quanto. O algoritmo foi criado a fim de ser mais eficiente em processamento de dados e mais robusto (obter sucesso sem ter que ajustar os hiper-parâmetros) (Schulman et al. (2017)).

SAC (ou Soft Actor-Critic) é um algoritmo do tipo off-policy que visa maximizar o retorno esperado e entropia, isto é, obter progresso agindo mais aleatoriamente possível. Isso é para evitar um problema comum em métodos que lidam com algorit-

mos de aprendizado de reforço que são livres de modelo: fragilidade a hiper-parametros (quando uma pequena mudança nestes gera um disturbio muito grande no desempenho do treino)([Haarnoja et al. \(2018\)](#))

2 Estado da Arte

Neste capítulo será discutido e analisados trabalhos que envolve a criação de agentes inteligentes em ambientes virtuais, a primeira seção será dedicada àqueles que não utilizam o pacote ML-Agents. A outra seção, porém será visto projetos que se utilizam da biblioteca da Unity3D.

TORCS e CARLA

TORCS é um simulador *open-source* bastante modular que pode ser usado para a criação de agentes artificialmente inteligentes. Sua portabilidade e modularidade é ideal para que se possa modificar o ambiente a fim de aumentar os desafios dos agentes que serão treinado nele, porém seu escopo se limita a pistas de corridas, então não é o ideal para percorrer trajetos urbanos que contenha pedestres, semáforos, regras de trânsito, etc(Wymann et al. (2013)).

Um projeto muito similar ao que este artigo se propõe a fazer é o **CARLA**. Car Learning to Act (CARLA) é um ambiente de código aberto de treinamento condução autônoma de veículos terrestres, foi desenvolvido usando a **Unreal Engine 4**. A simulação inclui clima dinâmico, uso de visão computacional, obstáculos dinâmicos como carros e pedestres além de visual fotorrealista. Quanto ao treinamento utiliza-se de três métodos: um fluxo modular, aprendizado por imitação e aprendizado por reforço, treinaram os agentes em cada método em 4 níveis diferentes de dificuldade, e então postos a testes em climas e uma cidade distinta. O resultado foi surpreendente, com o aprendizado por reforço tendo um desempenho muito inferior aos outros dois métodos (Dosovitskiy et al. (2017)).

Criação de agentes inteligentes utilizando ML-Agents

O projeto desenvolvido por (Urrea, Garrido e Kern (2021)) também envolve um carro autônomo, apesar de não envolver um ambiente urbano e sim uma pista em formato de 8 (para treino) e outra com começo e fim (para teste). O trabalho analisa o dados da dirigibilidade comparando um humano em um simulador, um agente criado usando aprendizado por imitação e outro agente utilizando **RL**.

Outro trabalho foi feito por (MÉXAS (2021)), que também se trata de um veículo autônomo, mas desta vez é um veleiro. Neste projeto, o autor faz um estudo comparativo dos algoritmos **PPO** e **SAC** para aprendizado por reforço, e os algoritmos **BC** e **GAIL** para **IL**. O ambiente dele leva em conta a ação do vento sobre o veleiro e ao analisar os

dados conclui que o primeiro algoritmo de **RL** é o que apresentou o melhor desempenho.

3 Materiais e Métodos

Para criar o projeto foi usado a Unity3D na versão **2022.3.7f1**. Acerca do **ML Agents**, há dois pacotes, o primeiro para o editor da Unity3D que adiciona os componentes e classes de **RL IL**, esta está na versão **2.0.1**. O outro pacote seria o pacote Python, instalado via **pip**(gerenciador de pacotes do Python), este encontra-se na versão **0.30.0**.

Como foi dito, para fazer o agente treinar é necessário criar um ambiente Python que interage com o editor da Unity informação, para isto foi usado Python na versão **3.9.13**, a principal dependência Python do **mlagents** é o *framework* **PyTorch**, neste projeto usa-se a versão **1.7.1**. As demais dependências Python estão presentes no requirements.txt disponíveis online no repositório oficial deste projeto que se encontra em <https://github.com/antunesvitor/SimuladorDeConducao>

Tanto a Unity quanto o Python estão presentes em para Windows e Linux, ambos os sistemas operacionais foram usados para o desenvolvimento deste projeto, porém grande parte dos testes foram conduzidos no **Arch Linux** utilizando-se do kernel **6.4.10-arch1-1**.

No repositório mencionado acima encontra-se também instruções de instalação tanto no **Windows** quanto no **Arch Linux**.

Parte II

Proposta

4 Modelo proposto

Neste capítulo se discutirá a proposta do sistema e seu desenvolvimento, será exposto como funciona todo o ambiente simulado. Dentre os sistemas que compõe um veículo autônomo o foco deste projeto será em desenvolver o componente de controle de deslocamento, isto é, ao agente é dado um trajeto o qual deve percorrer. O trajeto, em um contexto real seria definido por outro componente, porém aqui é predefinido pelo autor, não há necessidade de que os percursos sejam o mais eficiente possível, em vez disso o conjunto destes devem oferecer uma variedade de manobras a serem feitas pelo agente.

4.1 Ambiente

A simulação envolve em treinar o veículo para percorrer trajetos em ambiente urbano, a princípio, por uma questão de simplicidade o agente não terá de lidar com declives ou aclives, semáforos, outros veículos ou pedestres. Porém outros elementos estáticos comuns de uma cidade como calçadas, postes, árvores, prédios, etc. Portanto, o foco poderá se manter no estudo de fazer um agente percorrer as rotas. Às bordas do cenário há muros que limitam o alcance do veículo, foi concluído pelo autor que o tamanho atual é suficiente para os treinos iniciais, em estudos futuros pode ser considerado a expansão do cenário.




Figura 4 – Visão superior o cenário urbano criado para o treinamento do veículo

As rotas são compostas por: origem, *checkpoints* e destino. O primeiro indica o local de partida do veículo, o último é o objetivo final do agente naquele episódio. Os *checkpoints* são barreiras que indicam o caminho que deve ser percorrido, cada vez que o veículo atravessa uma delas ele ganha uma recompensa, isto é uma forma de indicar a ele que está fazendo o correto. Há 16 percursos predefinidos, cada uma delas possuem características distintas como distância origem-destino, quais e quantas conversões a serem feitas, isto fora pensado visando trazer uma diversidade maior de desafios a serem superados pelo agente. Assim como o tamanho do cenário, novos trajetos podem ser considerados em estudos futuros.




Figura 5 – Rota vista de perspectiva isométrica, o agente posicionado a origem ao canto esquerdo, com os *checkpoints* ao longo do percurso até o destino no canto direito.

4.2 Agente

Para o aprendizado o veículo possui 8 sensores apontando para todas as direções uniformemente espaçadas, estes sensores são um *component* do pacote **ML-agents** da Unity3D, são capazes de medir a distância dos objetos próximos ao veículo e também são capazes de distinguir quais são estes objetos. Estes sensores dentro do editor são representado por raio que partem do centro do veículo é possível configurar a diversos atributos deles como a quantidade, o ângulo máximo de distância do primeiro ao último, o ângulo vertical (que indica se eles apontam para cima ou para baixo) e o tamanho da esfera, que nada mais é que a tolerância de colisão do sensor.

Além dos sensores, foi adicionado a velocidade do veículo a lista de observações do agente. Vale lembrar que o não foi implementado um recurso de imagem em um primeiro momento, ou seja, o veículo só enxerga através dos sensores e tem ciência de sua própria velocidade, ele é "cego" a qualquer outro elemento do ambiente que não esteja se chocando com o sensor.




Figura 6 – Exemplo do agente e seus raios perceptores, é possível ver 6 raios laterais se chocando com as calçadas ao lado, o raio frontal se chocando com o *checkpoint*.

Quanto as ações que o agente pode fazer são apenas 3: acelerar, frear e direcionar as rodas a direita e a esquerda. A primeira e a última ação são chamadas ações contínuas, sendo assim um número que indica o nível de aceleração que o carro irá produzir, e no caso da direção da roda o quão direciona elas estão a esquerda ou direita. O ato de frear por outro lado é uma grandeza discreta e binária, não há pouca ou muita frenagem, simplesmente o veículo está ou não está freando.

4.3 Roteiro de treino

Parte III

Parte Final

5 Resultados e Discussão

Integer vel enim sed turpis adipiscing bibendum. Vestibulum pede dolor, laoreet nec, posuere in, nonummy in, sem. Donec imperdiet sapien placerat erat. Donec viverra. Aliquam eros. Nunc consequat massa id leo. Sed ullamcorper, lorem in sodales dapibus, risus metus sagittis lorem, non porttitor purus odio nec odio. Sed tincidunt posuere elit. Quisque eu enim. Donec libero risus, feugiat ac, dapibus eget, posuere a, felis. Quisque vel lectus ut metus tincidunt eleifend. Duis ut pede. Duis velit erat, venenatis vitae, vulputate a, pharetra sit amet, est. Etiam fringilla faucibus augue.

5.1 Base de Dados

Praesent facilisis, augue a adipiscing venenatis, libero risus molestie odio, pulvinar consectetur felis erat ac mauris. Nam vestibulum rhoncus quam. Sed velit urna, pharetra eu, eleifend eu, viverra at, wisi. Maecenas ultrices nibh at turpis. Aenean quam. Nulla ipsum. Aliquam posuere luctus erat. Curabitur magna felis, lacinia et, tristique id, ultrices ut, mauris. Suspendisse feugiat. Cras eleifend wisi vitae tortor. Phasellus leo purus, mattis sit amet, auctor in, rutrum in, magna. In hac habitasse platea dictumst. Phasellus imperdiet metus in sem. Vestibulum ac enim non sem ultricies sagittis. Sed vel diam.

5.2 Considerações Finais

Aenean velit sem, viverra eu, tempus id, rutrum id, mi. Nullam nec nibh. Proin ullamcorper, dolor in cursus tristique, eros augue tempor nibh, at gravida diam wisi at purus. Donec mattis ullamcorper tellus. Phasellus vel nulla. Praesent interdum, eros in sodales sollicitudin, nunc nulla pulvinar justo, a euismod eros sem nec nibh. Nullam sagittis dapibus lectus. Nullam eget ipsum eu tortor lobortis sodales. Etiam purus leo, pretium nec, feugiat non, ullamcorper vel, nibh. Sed vel elit et quam accumsan facilisis. Nunc leo. Suspendisse faucibus lacus.

Conclusões e Trabalhos Futuros

Proin non sem. Donec nec erat. Proin libero. Aliquam viverra arcu. Donec vitae purus. Donec felis mi, semper id, scelerisque porta, sollicitudin sed, turpis. Nulla in urna. Integer varius wisi non elit. Etiam nec sem. Mauris consequat, risus nec congue condimentum, ligula ligula suscipit urna, vitae porta odio erat quis sapien. Proin luctus leo id erat. Etiam massa metus, accumsan pellentesque, sagittis sit amet, venenatis nec, mauris. Praesent urna eros, ornare nec, vulputate eget, cursus sed, justo. Phasellus nec lorem. Nullam ligula ligula, mollis sit amet, faucibus vel, eleifend ac, dui. Aliquam erat volutpat.

Conclusões

Fusce vehicula, tortor et gravida porttitor, metus nibh congue lorem, ut tempus purus mauris a pede. Integer tincidunt orci sit amet turpis. Aenean a metus. Aliquam vestibulum lobortis felis. Donec gravida. Sed sed urna. Mauris et orci. Integer ultrices feugiat ligula. Sed dignissim nibh a massa. Donec orci dui, tempor sed, tincidunt nonummy, viverra sit amet, turpis. Quisque lobortis. Proin venenatis tortor nec wisi. Vestibulum placerat. In hac habitasse platea dictumst. Aliquam porta mi quis risus. Donec sagittis luctus diam. Nam ipsum elit, imperdiet vitae, faucibus nec, fringilla eget, leo. Etiam quis dolor in sapien porttitor imperdiet.

Cras pretium. Nulla malesuada ipsum ut libero. Suspendisse gravida hendrerit tellus. Maecenas quis lacus. Morbi fringilla. Vestibulum odio turpis, tempor vitae, scelerisque a, dictum non, massa. Praesent erat felis, porta sit amet, condimentum sit amet, placerat et, turpis. Praesent placerat lacus a enim. Vestibulum non eros. Ut congue. Donec tristique varius tortor. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Nam dictum dictum urna.

Phasellus vestibulum orci vel mauris. Fusce quam leo, adipiscing ac, pulvinar eget, molestie sit amet, erat. Sed diam. Suspendisse eros leo, tempus eget, dapibus sit amet, tempus eu, arcu. Vestibulum wisi metus, dapibus vel, luctus sit amet, condimentum quis, leo. Suspendisse molestie. Duis in ante. Ut sodales sem sit amet mauris. Suspendisse ornare pretium orci. Fusce tristique enim eget mi. Vestibulum eros elit, gravida ac, pharetra sed, lobortis in, massa. Proin at dolor. Duis accumsan accumsan pede. Nullam blandit elit in magna lacinia hendrerit. Ut nonummy luctus eros. Fusce eget tortor.

Trabalhos Futuros

Ut sit amet magna. Cras a ligula eu urna dignissim viverra. Nullam tempor leo porta ipsum. Praesent purus. Nullam consequat. Mauris dictum sagittis dui. Vestibulum sollicitudin consectetur wisi. In sit amet diam. Nullam malesuada pharetra risus. Proin lacus arcu, eleifend sed, vehicula at, congue sit amet, sem. Sed sagittis pede a nisl. Sed tincidunt odio a pede. Sed dui. Nam eu enim. Aliquam sagittis lacus eget libero. Pellentesque diam sem, sagittis molestie, tristique et, fermentum ornare, nibh. Nulla et tellus non felis imperdiet mattis. Aliquam erat volutpat.

Referências

- ANDRADE, A. Game engines: a survey. *EAI Endorsed Transactions on Game-Based Learning*, European Alliance for Innovation n.o., v. 2, n. 6, p. 150615, nov. 2015. Disponível em: <<https://doi.org/10.4108/eai.5-11-2015.150615>>. Citado na página 8.
- DOSOVITSKIY, A. et al. CARLA: An open urban driving simulator. In: LEVINE, S.; VANHOUCHE, V.; GOLDBERG, K. (Ed.). *Proceedings of the 1st Annual Conference on Robot Learning*. PMLR, 2017. (Proceedings of Machine Learning Research, v. 78), p. 1–16. Disponível em: <<https://proceedings.mlr.press/v78/dosovitskiy17a.html>>. Citado na página 17.
- HAARNOJA, T. et al. *Soft Actor-Critic Algorithms and Applications*. 2018. Citado na página 16.
- ITCH.IO. *Most used Engines*. [S.l.], 2023. Disponível em: <<https://itch.io/game-development/engines/most-projects>>. Citado na página 9.
- KELLEHER, J. D.; NAMEE, B. M.; D'ARCY, A. *Fundamentals of machine learning for predictive data analytics*. London, England: MIT Press, 2015. (The MIT Press). Citado na página 11.
- MÉXAS, R. P. Comparação do desempenho de algoritmos de aprendizado de máquina por reforço e por imitação na simulação de veleiros autônomos. *Universidade Federal Fluminense*, 2021. Citado na página 17.
- PADEN, B. et al. A survey of motion planning and control techniques for self-driving urban vehicles. *IEEE Transactions on Intelligent Vehicles*, Institute of Electrical and Electronics Engineers (IEEE), v. 1, n. 1, p. 33–55, mar. 2016. Disponível em: <<https://doi.org/10.1109/tiv.2016.2578706>>. Citado na página 7.
- RUSSELL, S.; NORVIG, P. *Artificial intelligence*. 3. ed. Upper Saddle River, NJ: Pearson, 2009. Citado 2 vezes nas páginas 10 e 11.
- SAE INTERNATIONAL. *Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles*. [S.l.], 2014. Disponível em: <https://www.sae.org/standards/content/j3016_202104/>. Citado 2 vezes nas páginas 1 e 7.
- SCHULMAN, J. et al. *Proximal policy optimization algorithms*. 2017. Disponível em: <<https://arxiv.org/abs/1707.06347>>. Citado na página 16.
- STEAMDB. *What are games built with and what technologies do they use?* [S.l.], 2023. Disponível em: <<https://steamdb.info/tech/>>. Citado na página 9.
- SUTTON, R. S.; BARTO, A. G. *Reinforcement Learning*. 2. ed. [S.l.]: MIT Press, 2018. Citado 3 vezes nas páginas 11, 12 e 14.
- URREA, C.; GARRIDO, F.; KERN, J. Design and implementation of intelligent agent training systems for virtual vehicles. *Sensors*, v. 21, n. 2, 2021. ISSN 1424-8220. Disponível em: <<https://www.mdpi.com/1424-8220/21/2/492>>. Citado na página 17.

WYMANN, B. et al. *TORCS, The Open Racing Car Simulator, v1.3.5*. 2013.
<<http://www.torcs.org>>. Citado na página 17.

Apêndices

APÊNDICE A – Primeiro Apêndice

Quisque facilisis auctor sapien. Pellentesque gravida hendrerit lectus. Mauris rutrum sodales sapien. Fusce hendrerit sem vel lorem. Integer pellentesque massa vel augue. Integer elit tortor, feugiat quis, sagittis et, ornare non, lacus. Vestibulum posuere pellentesque eros. Quisque venenatis ipsum dictum nulla. Aliquam quis quam non metus eleifend interdum. Nam eget sapien ac mauris malesuada adipiscing. Etiam eleifend neque sed quam. Nulla facilisi. Proin a ligula. Sed id dui eu nibh egestas tincidunt. Suspendisse arcu.

APÊNDICE B – Segundo apêndice com título tão grande quanto se queira porque ele já faz a quebra de linha da coisa toda

Maecenas dui. Aliquam volutpat auctor lorem. Cras placerat est vitae lectus. Curabitur massa lectus, rutrum euismod, dignissim ut, dapibus a, odio. Ut eros erat, vulputate ut, interdum non, porta eu, erat. Cras fermentum, felis in porta congue, velit leo facilisis odio, vitae consectetur lorem quam vitae orci. Sed ultrices, pede eu placerat auctor, ante ligula rutrum tellus, vel posuere nibh lacus nec nibh. Maecenas laoreet dolor at enim. Donec molestie dolor nec metus. Vestibulum libero. Sed quis erat. Sed tristique. Duis pede leo, fermentum quis, consectetur eget, vulputate sit amet, erat.

Donec vitae velit. Suspendisse porta fermentum mauris. Ut vel nunc non mauris pharetra varius. Duis consequat libero quis urna. Maecenas at ante. Vivamus varius, wisi sed egestas tristique, odio wisi luctus nulla, lobortis dictum dolor ligula in lacus. Vivamus aliquam, urna sed interdum porttitor, metus orci interdum odio, sit amet euismod lectus felis et leo. Praesent ac wisi. Nam suscipit vestibulum sem. Praesent eu ipsum vitae pede cursus venenatis. Duis sed odio. Vestibulum eleifend. Nulla ut massa. Proin rutrum mattis sapien. Curabitur dictum gravida ante.

Phasellus placerat vulputate quam. Maecenas at tellus. Pellentesque neque diam, dignissim ac, venenatis vitae, consequat ut, lacus. Nam nibh. Vestibulum fringilla arcu mollis arcu. Sed et turpis. Donec sem tellus, volutpat et, varius eu, commodo sed, lectus. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Quisque enim arcu, suscipit nec, tempus at, imperdiet vel, metus. Morbi volutpat purus at erat. Donec dignissim, sem id semper tempus, nibh massa eleifend turpis, sed pellentesque wisi purus sed libero. Nullam lobortis tortor vel risus. Pellentesque consequat nulla eu tellus. Donec velit. Aliquam fermentum, wisi ac rhoncus iaculis, tellus nunc malesuada orci, quis volutpat dui magna id mi. Nunc vel ante. Duis vitae lacus. Cras nec ipsum.

Anexos

ANEXO A – Nome do Primeiro Anexo

Sed mattis, erat sit amet gravida malesuada, elit augue egestas diam, tempus scelerisque nunc nisl vitae libero. Sed consequat feugiat massa. Nunc porta, eros in eleifend varius, erat leo rutrum dui, non convallis lectus orci ut nibh. Sed lorem massa, nonummy quis, egestas id, condimentum at, nisl. Maecenas at nibh. Aliquam et augue at nunc pellentesque ullamcorper. Duis nisl nibh, laoreet suscipit, convallis ut, rutrum id, enim. Phasellus odio. Nulla nulla elit, molestie non, scelerisque at, vestibulum eu, nulla. Ut odio nisl, facilisis id, mollis et, scelerisque nec, enim. Aenean sem leo, pellentesque sit amet, scelerisque sit amet, vehicula pellentesque, sapien.

ANEXO B – Nome de Outro Anexo

Phasellus id magna. Duis malesuada interdum arcu. Integer metus. Morbi pulvinar pellentesque mi. Suspendisse sed est eu magna molestie egestas. Quisque mi lorem, pulvinar eget, egestas quis, luctus at, ante. Proin auctor vehicula purus. Fusce ac nisl aliquam ante hendrerit pellentesque. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Morbi wisi. Etiam arcu mauris, facilisis sed, eleifend non, nonummy ut, pede. Cras ut lacus tempor metus mollis placerat. Vivamus eu tortor vel metus interdum malesuada.